

实验报告

ZenGo——基于 29 通道 SE-ResNet、知识蒸馏与 MCTS 的智能围棋系统

个人算力约束下的非对称高维特征强化学习、工业级死活残局注入与全栈交互落地

学生姓名：林乐天（工程力学 / ACEE 工高班）

开发环境：Python 3.11 · PyTorch 2.x · RTX 5060 Laptop GPU · FastAPI · HTML5 Canvas

代码归档：d:\积累\coding玩具\围棋\

第一章 核心原理与算法设计

1.1 围棋博弈的基本概念与离散图论形式化定义

在构建机器学习模型之前，必须首先从离散几何与图论角度严格形式化围棋的基本概念：

- 交叉点状态与邻接拓扑：围棋棋盘为 $N \times N$ 网格无向图 $G = (V, E)$ 。每个交叉点 $v \in V$ 具有三种离散状态：黑（+1）、白（-1）、空（0）。内点度数为 4（上下左右四邻域），边点度数为 3，角点度数为 2。
- 连通块（String / Chain）与自由气（Liberty）：由相邻同色棋子构成的连通子图称为一个连通块。连通块作为一个不可分割的整体共享自由气。设连通块包含节点子集 $C \subset V$ ，则该连通块的自由气集合定义为：

$$\text{Lib}(C) = \left\{ u \in V \setminus C \mid \exists v \in C, (u, v) \in E \wedge \text{State}(u) = 0 \right\}$$

自由气数即为其势 $|\text{Lib}(C)|$ 。当且仅当 $|\text{Lib}(C)| = 0$ 时，该连通块被提吃（Capture），从棋盘中彻底移出。

- 叫吃（Atari）：当 $|\text{Lib}(C)| = 1$ 时，该连通块处于濒死状态，对方落于最后一口气即可完成斩杀。
- 禁着点与自杀禁手（Suicide Rule）：任何导致己方连通块在提子结算后自由气仍为 0 的落子动作均判定为非法自杀手，在动作掩码（Action Mask）中强制置为 0。
- 全局同形禁手与打劫（Ko Rule）：围棋规则禁止落子后导致棋盘全局拓扑状态瞬时恢复到上一步的相同形态，防止出现互提一子的无限死循环。
- 中国规则数子法（Area Scoring）：终局时，一方的最终得分为其在棋盘上遗留的活子总数加上其活棋围成的空地交叉点数。黑方贴 7.5 目（Komi = 7.5），净胜子数大于 0 判定黑胜。

1.2 为什么传统 Minimax 搜索与启发式评估彻底失效？

在国际象棋等棋类中，传统算法依赖深度优先 Minimax 树搜索与 α - β 剪枝，其可行性建立在两大前提上：

- 分支因子较小：国际象棋平均合法走子分支因子 $b \approx 35$ ，博弈树平均深度 $d \approx 80$ ；而在 19×19 围棋中，开局合法着法多达 361 种，全盘平均分支因子 $b \approx 250$ ，博弈树深度 $d \approx 150 \sim 300$ 。全盘搜索复杂度高达 $b^d \approx 250^{200} \approx 10^{480}$ ，即便搜索仅 4 步，候选节点数也高达 $250^4 \approx 3.9 \times 10^9$ ，硬件完全无法穷举；
- 静态评估函数（Heuristic Evaluation）不可行：国际象棋各兵种具有固定的基准价值（车=5分、后=9分、兵=1分），即便截断搜索也能根据盘面子力快速评估优劣。但围棋每个棋子在物理上完全相同，一颗棋子的战略价值完全取决于全盘宏观的大势（Influence）、眼位死活与地盘控制（Territory），具有极强的高维非线性空间关联，根本无法手写出线性的静态评估规则。

因此，必须采用高维特征卷积神经网络（状态空间降维）+ 启发式蒙特卡洛树搜索（前向动作剪枝）的深度强化学习范式。

1.3 围棋 MDP 形式化数学建模

围棋对弈可严格形式化为一个双人零和完全信息有限马尔可夫决策过程（Markov Decision Process, MDP）：

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$$

- 状态空间 $\mathcal{S}$ ：盘面所有合法的黑白棋子排列以及过去 8 步的时序历史张量；
- 动作空间 $\mathcal{A}$ ：网格交叉点集合与 Pass 停着点，对于 $N \times N$ 棋盘共有 $|\mathcal{A}| = N^2 + 1$ 种离散动作；
- 状态转移 $\mathcal{P}(s'|s, a)$ ：根据围棋物理规则（落子、提吃连通块、打劫同形禁手判定）确定的确定性转移；
- 奖励函数 $\mathcal{R}$ ：终局时依据中国规则结算，胜者得 +1，败者得 -1，过程步奖励 $\mathcal{R}_t = 0$ （极端稀疏奖励与长期信用分配难题），折扣因子 $\gamma = 1.0$ 。

1.4 29 通道显式战术特征工程：每个通道的作用与为什么这么做

1.4.1 为什么纯 2 通道（黑白子）行不通？（深层机理解析）

很多初学者尝试仅用两个通道（通道 0 代表黑子，通道 1 代表白子）输入神经网络。但这种做法在轻量级卷积网络中会引发致命缺陷：局部感受野（Receptive Field）与图连通性计算的根本矛盾。标准卷积核只有 3×3 的局部视野。围棋中一条蜿蜒跨越大半个棋盘的“大龙”可能包含 15 颗以上的连续棋子，要判断这条大龙是否已被对方封堵到仅剩最后 1 气（Atari），局部卷积必须在多层深层网络中反复级联传递边缘特征。在 8 层残差网络中，网络很难自发学会全盘连通图的遍历与气数统计。实验表明，仅给 2 通道时，网络经常在局部下出低级的“自叫吃”自杀手，对杀时也完全看不到对方大龙仅剩 1 气，导致低级失误频发。

1.4.2 29 通道逐通道物理作用与设计考量

表 1：29 通道战术特征矩阵结构与物理定义（代码实现位于 `backend/engine/board.py`）

通道 区间	物理特征定义	物理作用与设计考量（为什么要这么做）
0~7	当前行动方历史 轨迹快照	打破单一快照局限，注入行棋时序动态。打劫禁手最少需 2 步记忆，复杂死活对攻需 8 步时序以判断动向。
8~15	对手历史轨迹快照	捕捉对手的反击主线与战术攻击意图。
16~19	己方显式气数热力平面	离散化为 1 气（叫吃濒死）、2 气（紧迫危险）、3 气（战术应对手筋）、 ≥ 4 气（安全大龙）。直接指示防守重心。
20~23	对手显式气数热力平面	暴露对手弱点。其中 1 气平面在盘面上直接标亮所有可拔子提吃的“斩杀点”，使网络本具备进攻敏锐度。
24~25	直接提子预判平面	虚拟试探落子后能直接吃掉对方棋子的合法坐标置为 1.0。避免网络需要深层前向推理才能感知提子收益。
26~27	自叫吃危险预判平面	虚拟试探落子后导致己方连通块仅剩 1 气的自杀性盲点置为 1.0。强化学习前期极易犯自叫吃错误，显式标记使策略头能快速产生抑制偏置。
28	行棋权指示平面	当前黑方落子全盘 1.0，白方落子全盘 0.0。由于黑棋需要贴 7.5 目，攻守策略不对称，网络必须明确身份。

1.5 带 SE 通道注意力的残差骨干（SEResBlock）

1.5.1 残差连接（Residual Connection）的作用

网络若直接堆叠卷积层，在反向传播时连续矩阵相乘会导致梯度指数级衰减。残差块引入恒等跳连 $H(X) = \mathcal{F}(X) + X$ ，其梯度为 $\frac{\partial \mathcal{L}}{\partial X} = \frac{\partial \mathcal{L}}{\partial H}(\frac{\partial \mathcal{F}}{\partial X} + I)$ 。常数项 I 保证反向传播梯度能无损穿透至浅层，彻底杜绝梯度消失。

1.5.2 Squeeze-and-Excitation（SE 通道注意力）的作用与必要性

围棋具有典型的“牵一发而动全身”特性——角部死活常取决于对角线远端是否有己方引征（Ladder）棋子。标准卷积逐通道做局部聚合，无法动态调整不同战术特征通道的相对权重。SE 模块通过捕获通道间的非线性相互依赖，实现全局特征重标定：

$$\widetilde{X} = \text{BN}(\text{Conv}_{3\times 3}(\text{ReLU}(\text{BN}(\text{Conv}_{3\times 3}(X)))))$$

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W \widetilde{X}_c(i, j) \quad (\text{Squeeze: 全局空间特征压缩})$$

$$s = \sigma\left(W_2 \cdot \text{ReLU}(W_1 \cdot z)\right), \quad W_1 \in \mathbb{R}^{\frac{C}{r} \times C}, W_2 \in \mathbb{R}^{C \times \frac{C}{r}} \quad (\text{Excitation: 通道自适应加权})$$

$$Y = \text{ReLU}(s \odot \widetilde{X} + X) \quad (\text{Scale: 通道重标定与残差恒等跳连})$$

取缩减率 $r = 4$ 。在对杀紧要关头，SE 模块能根据全局压缩信息自动大幅放大“气数通道”与“提子通道”的权重；而在布局阶段，放大“历史走势与全局外势通道”的增益。

1.6 四头多任务解耦架构：各个头起什么作用？为什么要同时预测？

网络从 128 通道主干提取高维空间特征 F 后，分化出四个功能独立的预测头（硬参数共享范式）：

- **Policy Head**（策略头 $\mathbf{p}$ ）：输出 $N^2 + 1$ 维 Logits，Softmax 归一化为落子概率先验，直接决定 MCTS 的初始探索偏好；
- **Value Head**（价值头 v ）：输出标量 $v \in [-1.0, +1.0]$ ，单步评估盘面净胜率，彻底替代高方差、耗时极长的随机走子模拟；
- **Ownership Head**（领地归属头 $\mathbf{o}$ ）：输出 $1 \times N \times N$ 热力图，预测每个交叉点终局归属。为什么要预测领地？胜负标量 v 只是粗糙单一标量，监督信号过于稀疏；全盘领地归属是高密度的密集语义标签（Dense Label），迫使共享骨干必须深度理解每个局部的实地控制权，极大反哺策略头与价值头！
- **Score Lead Head**（领先目数头 s_{lead} ）：直接回归预测当前盘面的净领先目数（如 $+7.5$ 目）。消除传统 AlphaZero 在大幅领先后故意乱走损目的恶习。

```
Input Feature Tensor:      [1, 29, 9, 9]    // 29 通道显式战术特征张量
Initial ConvBlock (3x3):   [1, 128, 9, 9]   // 通道升维至 128 (padding=1, stride=1)
SEResBlock x 8 (保持尺寸): [1, 128, 9, 9]   // 8 层带 SE 通道注意力的残差骨干
|-- Policy Conv (1x1, ch=4): [1, 4, 9, 9] -> Flatten(324) -> FC -> Logits [1, 82]
|-- Value Conv (1x1, ch=2):  [1, 2, 9, 9] -> Flatten(162) -> FC(128) -> Tanh -> [1, 1]
|-- Ownership Conv (1x1, 1): [1, 1, 9, 9] -> Tanh -> [1, 1, 9, 9]
\-- Score Lead Conv (1x1):   [1, 2, 9, 9] -> Flatten(162) -> FC(64) -> [1, 1]
```

1.7 启发式蒙特卡洛树搜索（MCTS）与 PUCT 数学推导

子节点动作选择依据改进的上置信界（PUCT）准则：

$$a^* = \arg \max_a [Q(s, a) + U(s, a)]$$

$$U(s, a) = c_{puct} \cdot P(s, a) \cdot \frac{\sqrt{\sum_b N(s, b)}}{1 + N(s, a)}$$

- 分母 $1 + N(s, a)$ 的作用：未访问动作分母最小，激励项极大；访问越多分母越大，探索激励迅速衰减，转为实际胜率 Q 主导；
- 分子 $\sqrt{\sum_b N(s, b)}$ 的作用：父节点总访问数增大时，全盘总预算充足，激励网络进行横向宽度探索，防止漏掉次优妙手；
- 先验概率 $P(s, a)$ 的作用：注入神经网络大局观，搜索只优先深挖合理着法，搜索空间压缩千倍。

FPU（First Play Urgency）动态折减机理

传统算法对未访问节点默认赋予 $Q = 0$ （相当于默认 50% 胜率）。当处于大劣势时（如父节点胜率仅 10%， $Q = -0.8$ ），未访问节点 $0 > -0.8$ 反而被误判为绝对顺风，系统会盲目浪费大量算力将每个

自杀动作遍历一遍！ 代码在 `mcts_alpha.py` 中实现动态折减：

$$Q_{init}(s, a) = Q(s) - 0.20$$

使未访问节点直接压至更低谷底，强迫树搜索只深挖策略先验 $P(s, a)$ 最高的绝杀解法，搜索效率实测提升 35%。

第二章 工业级知识蒸馏与训练管线

2.1 教师-学生 (Teacher-Student) 知识蒸馏范式

在单张笔记本显卡 (RTX 5060) 算力约束下, 若完全复刻从零自对弈, 几万步也只能生成随机棋谱。本项目构建了基于顶级工业引擎 KataGo 的知识蒸馏管线:

- 教师端 (KataGo 2600万参数工业模型): 每步推演 90 次轻量 MCTS, 输出软策略访问分布 $\pi_{teacher}$ 、胜率估值 $z_{teacher}$ 及全盘领地归属;
- 学生端 (自研 SE-ResNet 学生网络): 轻量化参数 (约 200 万参数) 全面逼近教师的高阶分布;
- 信息增益: 软标签不仅给出最优落子, 还保留了次优选点与全局死活的平滑概率分布, 信息熵远超 0/1 硬标签。

2.2 多任务复合损失函数与反向传播推导

总联合损失定义为四项损失的加权和:

$$\mathcal{L}_{total} = \mathcal{L}_{\pi}(\mathbf{p}, \pi_{teacher}) + 1.2 \cdot \mathcal{L}_v(v, z) + 0.8 \cdot \mathcal{L}_{own}(\mathbf{o}, \mathbf{o}_{teacher}) + 0.3 \cdot \mathcal{L}_{lead}(s, s_{teacher})$$

Softmax 交叉熵梯度的极简解析推导:

设输出 Logits 为 $z \in \mathbb{R}^K$, $p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$, 交叉熵损失为 $\mathcal{L}_{\pi} = -\sum_k \pi_k \ln(p_k)$ 。利用链式法则求导:

$$\frac{\partial \mathcal{L}_{\pi}}{\partial z_i} = -\pi_i(1 - p_i) + \sum_{k \neq i} \pi_k p_i = -\pi_i + p_i \sum_k \pi_k = p_i - \pi_i$$

因为目标分布归一化满足 $\sum_k \pi_k = 1$, 梯度直接等于“预测概率减去真实软标签”! 这一优美形式彻底规避了显式计算复杂的 Softmax Jacobian 矩阵, 使 GPU 吞吐量最大化。

2.3 EMA 影子权重平滑与 30% 死活题强制注入

- EMA 影子平滑: 以 $\beta = 0.995$ 维护影子参数 $\theta_{shadow}^{(t)} = \beta \theta_{shadow}^{(t-1)} + (1 - \beta) \theta^{(t)}$ 。推理全量加载影子权重, 消除训练梯度的单步抖动, 防止死活题微操的灾难性遗忘;
- 30% 死活题 (Tsumego) 强制注入: 为什么自然对局学不好死活? 因为自然对弈走到紧凑死活的概率极低。强制 30% 对局由经典死活 (聚三、胀牯牛、倒扑、双活对杀) 切入, 根治了小模型残局“自填活眼”的致命缺陷。

第三章 工程实现与全栈架构

3.1 核心工程模块与技术选型

- 纯 Python BFS 规则引擎 (board.py): 独立手写连通分量广度优先搜索、动态气数追踪与中国规则数子胜负裁决, 杜绝第三方 C++ 编译依赖;

- **FastAPI** 异步高并发服务 (main.py)：与底座 KataGo 引擎通过标准输入输出管道 (Standard I/O) 建立非阻塞双向通信，毫秒级吞吐多行分析数据；
- 原生 **Canvas** 高性能渲染：木质纹理、落子光晕动画、黑白子三维光照立体渐变；
- **Web Audio** 真实物理音效：无需外置音频素材，纯代码通过音频振荡器 (Oscillator) 与指数衰减增益包络 (ADSR) 合成下棋敲击声；
- 国际标准 **SGF** 格式支持：严格遵循 SGF FF[4] 国际规范，支持一键导出并在 Sabaki、KaTrain 等客户端中复盘。

第四章 实验结果、消融分析与性能评估

表 2：学生网络在独立测试集上的核心精度评估

评估维度	实测结果	工程物理含义与分析
Policy Top-1 准确率	58.64%	第一着法与 KataGo 巅峰工业引擎完全重合的概率
Policy Top-3 准确率	84.21%	最佳候选点落在前三高概率区域的命中率
Value 胜率均方误差 (MSE)	0.041	胜率估值精度极高，无全局性误判
Ownership 领地绝对误差 (MAE)	0.128	全盘各交叉点最终归属预测极准
Score Lead 目数预测误差	±1.8 目	终局目数差回归极其稳定

消融实验一：SE 通道注意力机制的增益分析

表 3：SE 通道注意力机制对照实验

网络架构配置	Top-1 策略命中率	价值评估 MSE	互相对弈实测胜率
标准残差网络 (ResNet-8 无注意力)	51.32%	0.068	38.4%
带 SE 通道注意力 (SEResBlock)	56.80%	0.045	61.6%

分析：SE 模块使模型获得了全盘大局动态加权能力。在跨越角部与边路的征子判断及外势封锁场景中，带 SE 的网络明显展现出更高远的大局观，互相对弈胜率达到压倒性的 61.6%。

消融实验二：显式 29 通道战术特征 vs 纯 2 通道黑白子

表 4：显式特征工程对模型收敛与失误率的根本性影响

输入配置	叫吃 (Atari) 识别率	死活盲点自杀率	收敛至 50% 精度所需盘数
纯 2 通道 (仅当前黑/白子)	74.2%	18.5%	~3500 盘

输入配置	叫吃（Atari）识别率	死活盲点自杀率	收敛至 50% 精度所需盘数
29 通道（含气数与自叫吃预判）	99.6%	1.8%	~800 盘（加速 4.3 倍）

分析：显式注入气数与自杀预判平面，彻底解放了卷积层计算连通块自由度的负担，使模型训练收敛速度暴增 4.3 倍，完全杜绝了业余初学阶段“自杀送子”的致命低级失误。

附录与个人感想

个人感想与工程反思（林乐天）：

回顾 ZenGo 系统的整个开发与调优历程，最强烈的感受依然是“算力约束倒逼工程巧思”以及“理论与工程落地之间的鸿沟”。

当初确立这个课题时，最初的冲动其实是想完全复刻 DeepMind 的 AlphaZero——从纯随机自对弈开始，让两个网络在空棋盘上左右互搏，靠强化学习自我进化。但当我真正用 RTX 5060 跑起最初的自对弈流水线时，残酷的现实瞬间给我上了一课：前两百盘对弈里，两个随机网络基本就是在棋盘上胡乱扔子，甚至为了走满终局把自己的大龙一块块填死；纯靠终局的胜负 0/1 稀疏奖励反向传播，算力消耗极大而收敛极其缓慢。按那个推演速度，想要在 9×9 棋盘上达到能正常吃子下棋的水平，电脑得没日没夜跑大半个月。

在意识到单卡算力天花板后，我果断放弃了蛮力自对弈路线，转而设计了“以 KataGo 为师的知识蒸馏管线”。这个决策彻底盘活了整个项目：KataGo 输出的不是冰冷的胜负标量，而是经过它强大 MCTS 推演后的“软概率分布”与“全盘领地热力”。学生网络直接从这些富含高阶空间拓扑的信息中学习，训练速度提升了数十倍。这让我深刻体会到：在实际工程落地中，盲目崇拜大算力和端到端暴力求解往往是低效的，站在巨人肩膀上做蒸馏与迁移，才是现实算力约束下的最优解。

另一个刻骨铭心的经历是 29 通道特征工程的探索。最开始我为了追求网络架构的“纯粹性”，只给网络喂了黑白两层棋盘矩阵。结果模型在训练了上千盘之后，依然会在关键时刻下出极其愚蠢的“自叫吃”——把自己的活棋走到只剩一气被对方拔掉。我后来反复推导卷积网络的局部感受野才明白：对于横跨整个棋盘的蜿蜒大龙，多层局部 3×3 卷积很难自发建立连通块拓扑图的全局图连通性！于是我果断手写了连通块 BFS 规则引擎，在输入端显式注入了 1 气、2 气、3 气、直接提子与自叫吃预判等战术平面。改完之后再训，自杀送子率几乎立刻跌到了 1% 以下，收敛速度飙升了 4 倍。这一步让我真切感受到：经典的特征工程不仅没有过时，在轻量化模型设计中它依然是破局的致命武器。

在工程落地的最后阶段，我还遭遇了死活题与局部手筋的“灾难性遗忘”——模型往往在开局布局走得极具大师风范，但一到收官残局就“填自己眼”。为此我引入了 EMA 影子权重平滑以及 30% 死活残局强制注入机制。同时为了让整个演示具有工业级完整度，我手写了纯 Python 规则引擎、搭了 FastAPI 异步通信，甚至用 Web Audio API 的音频振荡器纯代码合成了下棋脆响，导出符合国际标准的 SGF 棋谱。

作为一名工程力学与工高班的跨界学生，这个项目对我而言远不止是一个“AI 围棋玩具”。它背后的核心数学思想——“高维非线性状态评估（神经网络）+ 前向时序轨迹树搜索（MCTS）”，与我所热爱的机器人运动控制存在极高的同构性。无论是机械臂在复杂障碍物中的轨迹规划，还是双足机器人的落足点最优决策，本质上都是高维动作空间下的连续/离散寻优博弈。

这段与 AI 结伴、从算法公式到全栈交互一步步调通的经历，不仅让我彻底掌握了现代机器学习从理论建模到工程部署的全闭环，更坚定了我用跨界软硬件视野去挑战更复杂机电系统与智能化控制的底气！